

итоговая работа

№ 1.1

Итоговая работа Зименкова → 11212

№ 1.1

Вероятность одной ошибки составляет 30%, вероятность того, что произойдет более одной ошибки, составляет 10%. Вероятность перезаключения контракта в случае наличия ровно одной ошибки составляет 30%, в случае более одной ошибки составляет 50%, а в случае отсутствия — 90%. Какова вероятность перезаключения?

$$\begin{array}{ll} A - \text{одна ошибка} & P(A) = 0,3 \\ B - > 1 \text{ ошибки} & P(B) = 0,1 \\ C - \text{нет ошибок} & P(C) = 1 - P(A) - P(B) = 0,6 \end{array}$$

И - контракт перезаключен

$$\begin{array}{l} P(H|A) = 0,3 \\ P(H|B) = 0,5 \\ P(H|C) = 0,9 \end{array}$$

по формуле полной вероятности

$$P(H) = P(H|A) \cdot P(A) + P(H|B) \cdot P(B) + P(H|C) \cdot P(C) = 0,3 \cdot 0,3 + 0,5 \cdot 0,1 + 0,9 \cdot 0,6 = 0,09 + 0,05 + 0,54 = 0,68$$

Ответ: $P(H) = 0,68$

№ 2.1

№ 2.1

В результате каждой покупки вы получаете первый купон с вероятностью 0,8, а второй с вероятностью 0,2.

Сколько в среднем нужно сделать покупок, чтобы собрать оба купона?

$$\begin{array}{l} P_1 = 0,8 - \text{получил 1й купон} \\ P_2 = 0,2 - \text{получил 2й купон} \end{array}$$

М - среднее кол-во покупок, которое нужно сделать, чтобы собрать оба купона

M_1 - кол-во ... чтобы один купон $M_1 = 1$
 M_2 - кол-во ... чтобы 2й купон, если уже есть 1й, или 1й, если уже есть 2й.

$$M_2 = P_1 \cdot M(2\text{й к.}) + P_2 \cdot M(1\text{й к.})$$

т.к. сбор оставшихся купонов распред. геометрически, то:

$$M(1\text{й к.}) = \frac{1}{P_1} = \frac{10}{8}$$

$$M(2\text{й к.}) = \frac{1}{P_2} = \frac{10}{2}$$

$$M_2 = \frac{8}{10} \cdot \frac{10}{2} + \frac{2}{10} \cdot \frac{10}{8} = \frac{8}{2} + \frac{2}{8} = \frac{16}{4} + \frac{1}{4} = \frac{17}{4}$$

$$M = M_1 + M_2 = 1 + \frac{17}{4} = \frac{21}{4} = 5,25$$

Ответ: 5,25 покупок

№ 3.2

ноутбук colab: https://colab.research.google.com/drive/1zNVAJ6RLzIYrsBqABYtzh7pYUqy_v3E4?usp=sharing
[\(https://colab.research.google.com/drive/1zNVAJ6RLzIYrsBqABYtzh7pYUqy_v3E4?usp=sharing\)](https://colab.research.google.com/drive/1zNVAJ6RLzIYrsBqABYtzh7pYUqy_v3E4?usp=sharing).

Сгенерируйте 200 выборок размера 500 из $\text{Exp}(1)$. Посчитайте для каждой выборки статистику Колмогорова. Нарисуйте гистограмму по полученному набору статистик. На нем же изобразите график теоретической плотности распределения Колмогорова. Согласуется ли результат с теорией?

PYTHON

```
import numpy as np
from scipy.stats import kstest, expon
import matplotlib.pyplot as plt

# параметры
n = 200 # число выборок
sample_size = 500 # размер каждой выборки

# массив с выборками
samples = np.random.exponential(scale=1, size=(n, sample_size))

# массив со статистиками Колмогорова
ks_stats = []

# считаем статистики
for sample in samples:
    stat, p_value = kstest(sample, 'expon', args=(0,1))
    ks_stats.append(stat)

ks_stats = np.array(ks_stats)

# одновыборочный ks-тест для проверки согласия с теорией

from scipy.stats import kstest, kstwobign # распределение Колмогорова

print("KS-тест для проверки согласия с теоретическим распределением:")

ks_stat, ks_pvalue = kstest(
    ks_stats,
    lambda x: kstwobign.cdf(x * np.sqrt(sample_size))
)

print("KS-статистика: ", ks_stat)
print("p-value: ", ks_pvalue)

if ks_pvalue > 0.05:
    print("Гипотезу можно принять - распределение согласуется с теоретическим")
else:
    print("Гипотезу следует отвергнуть - распределение не согласуется с теоретическим")

plt.figure(figsize=(14, 10))

# график - гистограмма с плотностью
x_values = np.linspace(min(ks_stats), max(ks_stats), 200)
kstwobign_pdf = kstwobign.pdf(x_values * np.sqrt(sample_size)) * np.sqrt(sample_size)

plt.hist(ks_stats, bins=20, density=True, edgecolor='black', alpha=0.5, label='Эмпирическая гистограмма')
plt.plot(x_values, kstwobign_pdf, 'r-', lw=2, label='Теоретическая плотность')
plt.xlabel('Статистика Колмогорова D_n', fontsize=11)
plt.ylabel('Плотность', fontsize=11)
plt.title('Распределение статистики Колмогорова', fontsize=11)
plt.legend(fontsize=11)
plt.grid(axis='y', linestyle='--', alpha=0.5)

plt.show()
```

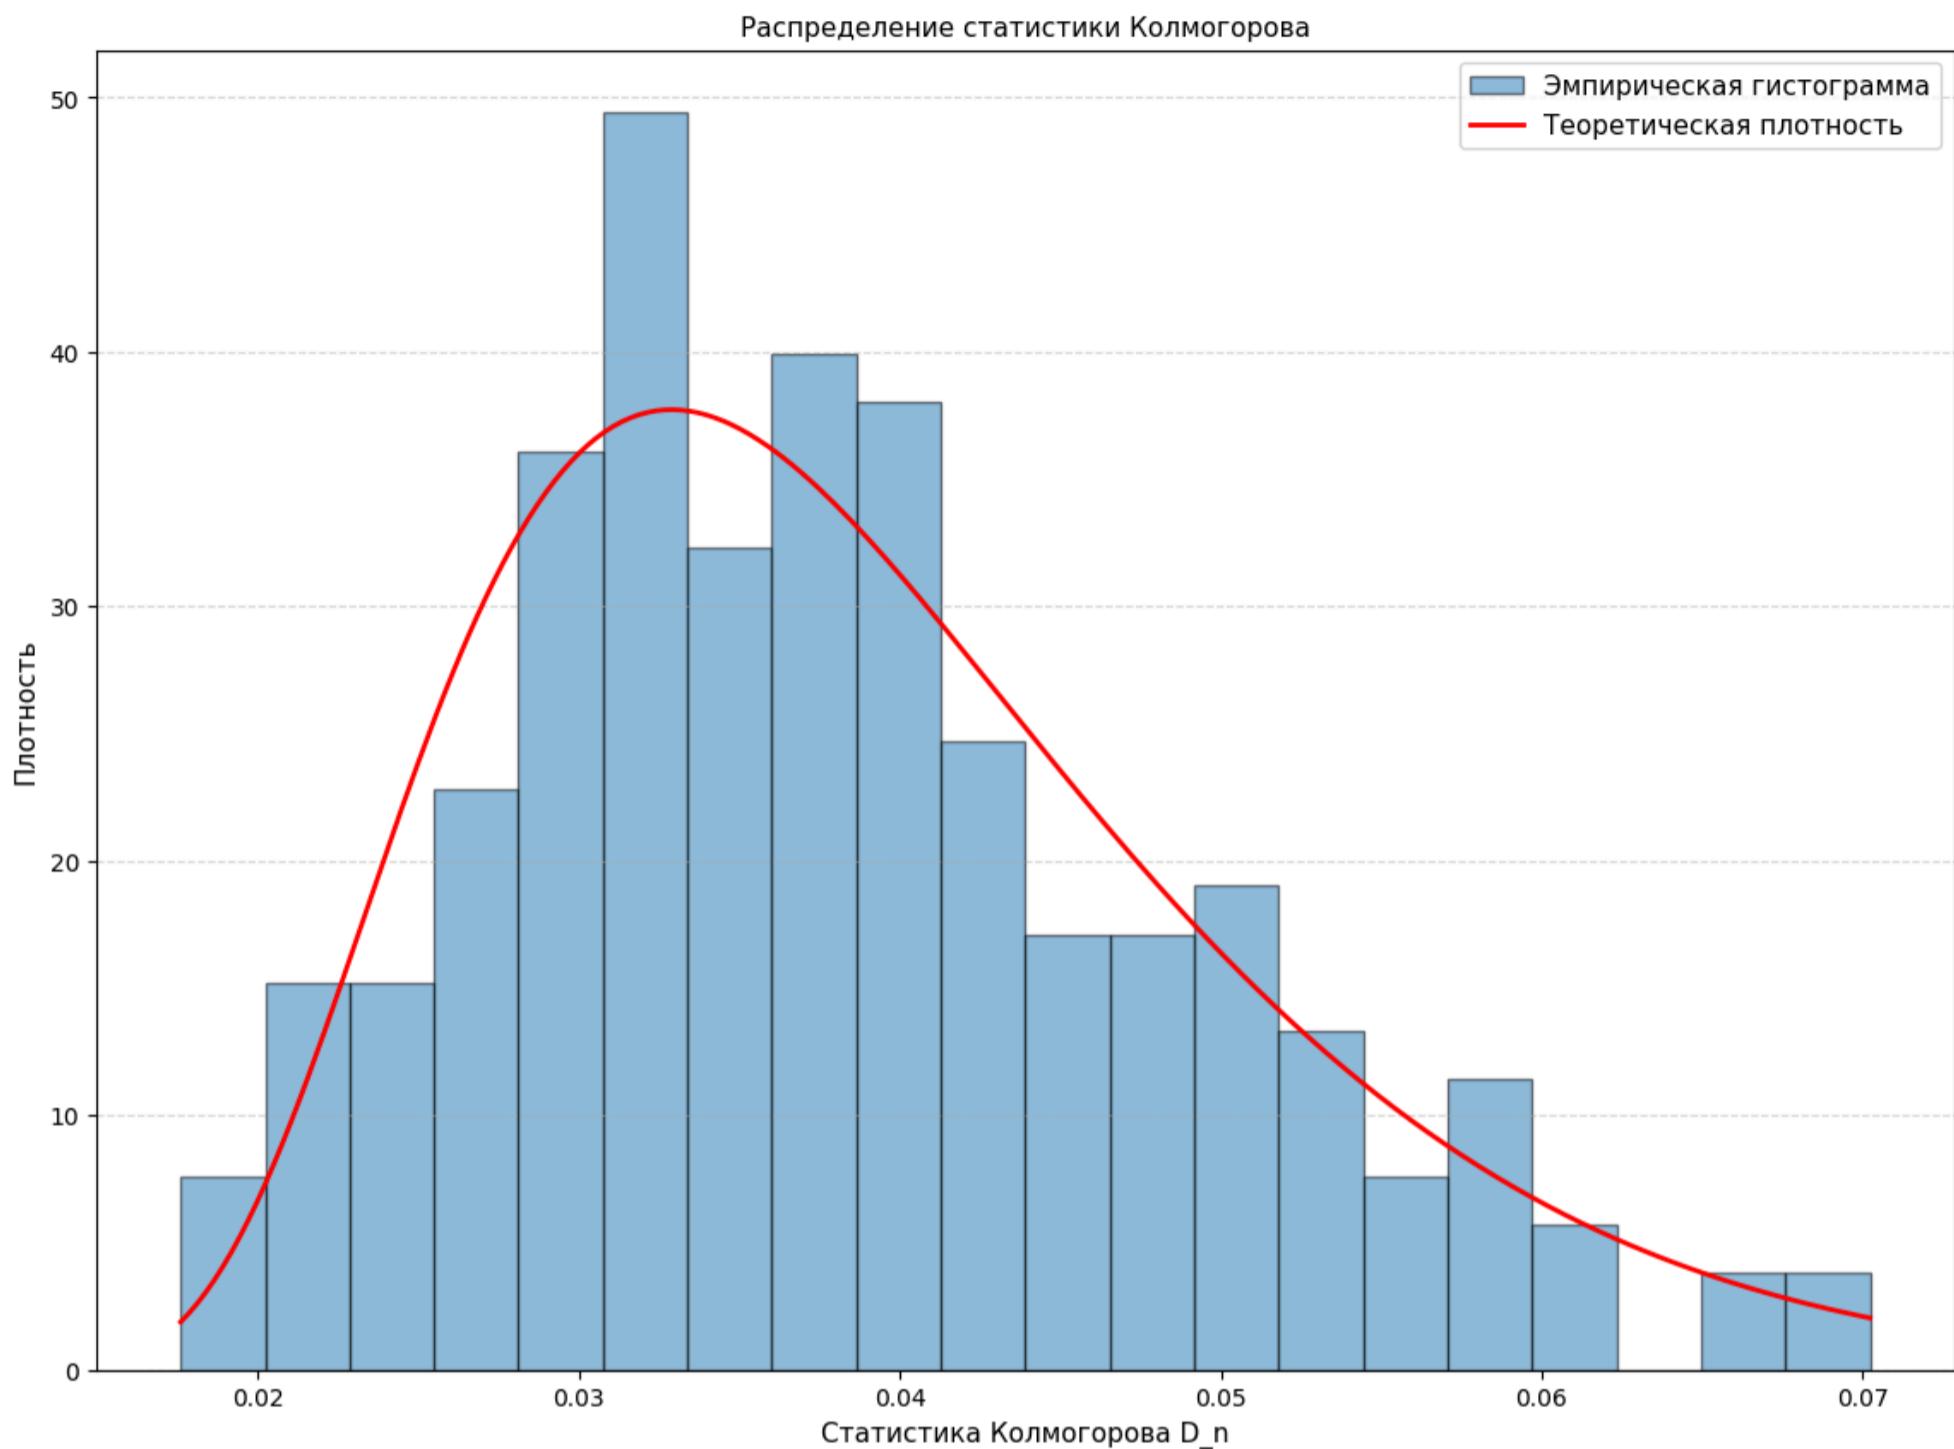
Результат

KS-тест для проверки согласия с теоретическим распределением:

KS-статистика: 0.04529923507533962

p-value: 0.7889880982071726

Гипотезу можно принять - распределение согласуется с теоретическим



Вывод

Получившаяся гистограмма наглядно показывает, что сгенерированный результат хорошо совпадает с теоретическим распределением. Это также подтверждается KS-тестом: получилось довольно большое значение p-value, а значит, эмпирические данные действительно хорошо совпадают с теоретическим распределением. Небольшие отклонения (выходы столбцов и выбросы в правом хвосте) обоснованы случайными вариациями и небольшим объемом выборки.

Конечно, если запускать случайную генерацию много раз, результаты могут получиться разными - иногда появляются заметные выбросы, которые визуально сильно выделяются из графика, а KS-тест показывает, что распределение не совпало, но это в целом ожидаемо из-за случайной генерации и небольшого объема выборки.

№ 4.1

Из загруженного набора акций с 2014 года по конец 2022 года возьмите нужную по счету акцию в файле, соответствующую номеру этой задачи, и для нее по close values посчитайте 5-дневный 5-% VaR логарифмической доходности (по выборке). На тестовой части выборки (2023 год) проведите бэктестинг оцененного VaR одним из частотных тестов.

1-й вариант - AAPL

PYTHON

```
import pandas as pd
import numpy as np
from scipy.stats import chi2, chi2_contingency
import matplotlib.pyplot as plt

# загружаем данные
df = pd.read_csv('data.csv')
df['Date'] = pd.to_datetime(df['Date'])
df = df.sort_values('Date')
ticker = 'AAPL'

# разделяем train/test
train = df[df['Date'] < '2023-01-01'].copy()
test = df[(df['Date'] >= '2023-01-01') & (df['Date'] < '2024-01-01')].copy()

# лог-доходности будем разбивать на блоки по 5 дней
size = 5

# тренировочные данные
train_prices = train[ticker].values
train_dates = train['Date'].values
train_logreturns = np.log(train_prices[1:] / train_prices[:-1])
n_train_blocks = len(train_logreturns) // size

train_block_logreturn = [
    train_logreturns[i * size: (i+1) * size].sum() for i in range(n_train_blocks)
]
train_block_ends = [
    train_dates[(i + 1) * size] for i in range(n_train_blocks)
]

# тестовые данные
test_prices = test[ticker].values
test_dates = test['Date'].values
test_logreturns = np.log(test_prices[1:] / test_prices[:-1])
n_test_blocks = len(test_logreturns) // size

test_block_logreturn = [
    test_logreturns[i * size: (i+1) * size].sum() for i in range(n_test_blocks)
]
test_block_ends = [
    test_dates[(i + 1) * size] for i in range(n_test_blocks)
]

# расчет VaR 5% (квантиль по train)
var_5p_5d = np.quantile(train_block_logreturn, 0.05)
print("5-дневный VaR 5% по блочным лог-доходностям (тренировочные данные): ", var_5p_5d)

# проверяем нарушения VaR на тестовых данных

# exs = np.array([float(y) for y in test_block_logreturn])
# print(exs)

exc = np.array([int(x < var_5p_5d) for x in test_block_logreturn])
n = len(exc)
x = exc.sum() # исключения
alpha = 0.05 # целевая частота исключений
```

```

# бэктест методом Купика (пропорциональный тест, POF)
if 0 < x < n:
    pi_hat = x / n
    # LR-статистика Купика
    lr = -2 * ((x*np.log(alpha) + (n - x) * np.log(1 - alpha)) -
                (x * np.log(pi_hat) + (n - x) * np.log(1 - pi_hat)))
    p_value = 1 - chi2.cdf(lr, df=1)
else:
    lr = np.False_p_value = np.nan

print()
print('-----')
print("Бэктестинг VaR на тестовых данных:")
print()
print("Ожидаемых нарушений VaR (n * alpha): ", n * alpha)
print("Фактических нарушений VaR (x): ", x)
print("p_value: ", p_value)

if p_value > 0.05:
    print("p_value > 0.05, нет оснований отвергать правильность VaR")
else:
    print("p_value < 0.05, VaR отвергается, частота нарушений не совпадает с теоретической")

# график train (тренировочные данные и VaR)
plt.figure(figsize=(12, 6))
plt.plot(train_block_ends, train_block_logreturn, linestyle='-', 
         label='Тренировочные данные в 5-дневных блоках')
plt.axhline(var_5p_5d, color='red', linestyle='--', label='VaR 5% train')
plt.title('5-дневные блочные лог-доходности и VaR (тренировочные данные)')
plt.xlabel('Даты')
plt.ylabel('Лог-доходность за 5 дней')
plt.legend()
plt.tight_layout()
plt.show

# график test (тестовые данные и нарушения VaR)
plt.figure(figsize=(12, 4))
plt.plot(test_block_ends, test_block_logreturn, marker='o', 
         label='Тестовые данные в 5-дневных блоках')
plt.axhline(var_5p_5d, color='red', linestyle='--', label='VaR 5% test')
plt.scatter([test_block_ends[i] for i in range(n) if exc[i] == 1],
            [test_block_logreturn[i] for i in range(n) if exc[i] == 1],
            color='red', zorder=5, label='Нарушения VaR')
plt.title('Нарушения VaR 5% по блокам (тестовые данные)')
plt.xlabel('Даты')
plt.ylabel('Лог-доходность за 5 дней')
plt.legend()
plt.tight_layout()
plt.show

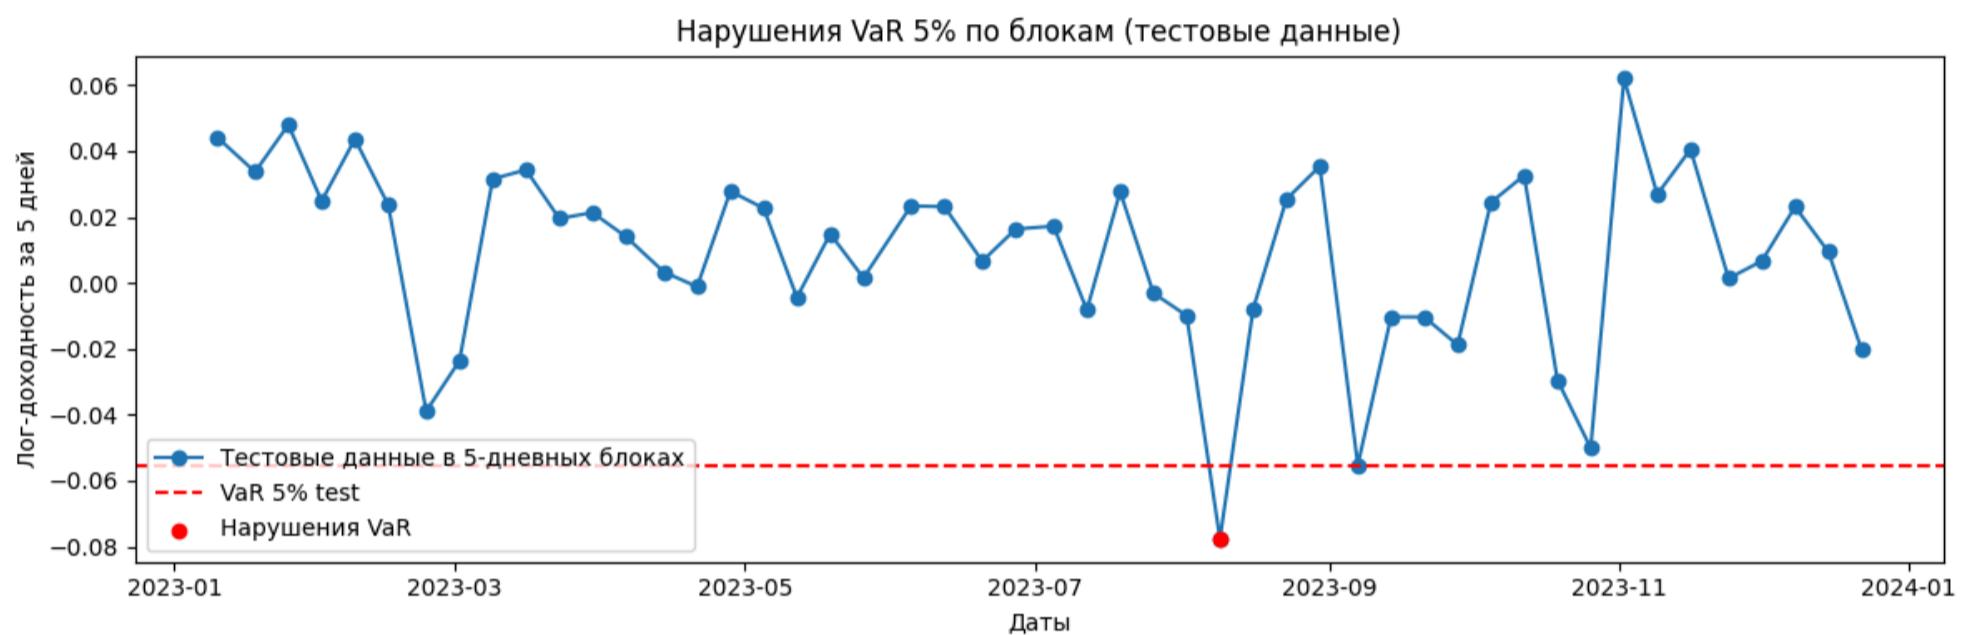
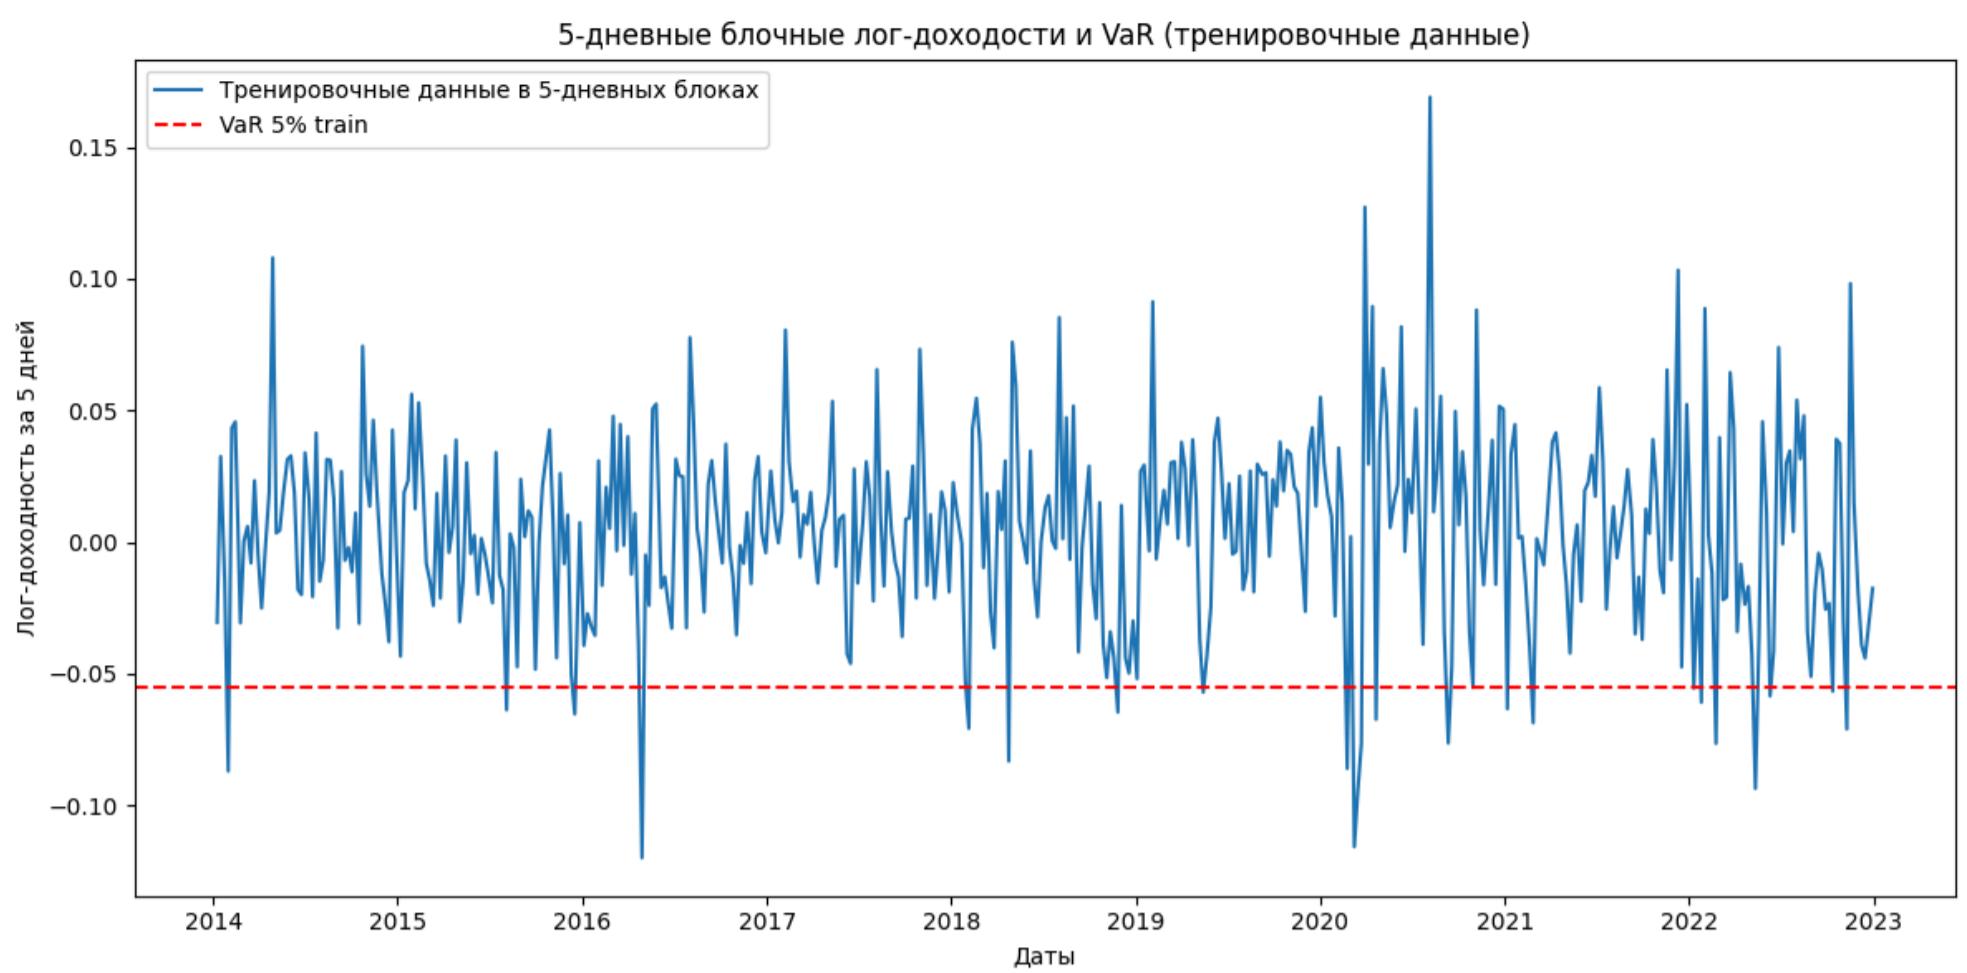
```

Результат

5-дневный VaR 5% по блочным лог-доходностям (тренировочные данные): -0.055315535814685804

Бэктестинг VaR на тестовых данных:

Ожидаемых нарушений VaR (n * alpha): 2.45
Фактических нарушений VaR (x): 1
p_value: 0.283020441561747
p_value > 0.05, нет оснований отвергать правильность VaR



Вывод

5-дневный VaR 5% = -0.05531553. За 5 дней лог-доходность акции не упадет ниже -5,53%.

Нарушений: 1 из 49. Ожидаемое кол-во - $49 \cdot 0,05 = 2,45$.

Достаточно большое p-value и маленькое количество нарушений VaR ($1 < 2,45$) показывают, что VaR рассчитан верно. Одно значение было довольно близко к VaR: -0.05526984, когда VaR -0.05531553, и его видно на графике, однако все же лог-доходность в этом блоке больше, чем VaR. В любом случае, 2 нарушения это все еще в пределах ожидаемого количества.

№ 5.2

нс 5.2

$$M(X) = M_x = 8 \quad M(Y) = M_y = 100$$

$$\text{Var}(X) = \sigma_x^2 = 2^2 \quad \text{Var}(Y) = \sigma_y^2 = 10^2$$

$$\text{Cov}(X, Y) = \rho = -0,5$$

регрессия Y на X :

$$Y = \beta_0 + \beta_1 X + \varepsilon \quad M(\varepsilon) = 0 \quad x_0 = 9$$

1. найти β_0, β_1

$$\beta_0 = M(Y) - \beta_1 M(X) \quad \beta_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

$$\text{Cov}(X, Y) = \text{Cov}(X, Y) \cdot \sigma_x \cdot \sigma_y \Rightarrow \beta_1 = \frac{\rho \cdot \sigma_x \cdot \sigma_y}{\sigma_x^2} = \frac{\rho \sigma_y}{\sigma_x} = \frac{-0,5 \cdot 10}{2} = -2,5$$

$$\beta_0 = 100 - (-2,5) \cdot 8 = 100 + 20 = 120$$

2. найти уравнение $\hat{Y} = \beta_0 + \beta_1 X$

$$\hat{Y} = 120 - 2,5X$$

3. найти \hat{Y} при $x_0 = 9$

$$\hat{Y}(x_0) = 120 - 2,5 \cdot 9 = 97,5$$

4. найти R^2

м.к. регрессия просимая, то $R^2 = \text{Cov}^2(X, Y) / \rho^2 = 0,25$

Ответ: 1. $\beta_0 = 120$ 2. $\hat{Y} = 120 - 2,5X$

3. $\hat{Y}(x_0) = 97,5$ 4. $R^2 = 0,25$

спасибо за курс! Это было трудно, но интересно ::

- подлинельница математических операторов,

Σ оптим